



Thiết kế kỹ thuật: Pipeline phân loại tài liệu theo domain (đa phòng ban)



Mục tiêu: chuyển pipeline ingest từ "đóng cứng cho bản vẽ cơ khí" sang "đa domain" — mỗi loại tài liệu (cơ khí, kỹ thuật, kế toán, nhân sự, chung) đi qua bộ trích xuất, schema, và cách tính chất lượng riêng. Tài liệu này kèm hướng dẫn triển khai từng bước có ví dụ code.



Đây là bản thiết kế đề xuất. Tất cả đoạn code là minh họa để bạn áp dụng vào source thật (`src/mech_chatbot/...`). Hãy chạy trên nhánh `git` riêng và test kỹ trước khi merge.

1. Vấn đề với kiến trúc hiện tại

Thành phần	Hiện trạng	Hệ quả khi đa phòng ban
<code>classify_document()</code>	Chỉ trả <code>technical_drawing</code> / <code>bom</code> / <code>other</code> , lỗi thì mặc định <code>technical_drawing</code>	Hoá đơn, hợp đồng bị coi là bản vẽ
<code>extract_metadata_smart()</code>	Regex cơ khí (mã bản vẽ, vật liệu, dung sai, công đoạn)	Tài liệu HR/kế toán → metadata rỗng
<code>calculate_quality_status()</code>	Trừ 30 điểm nếu không có thuộc tính kỹ thuật	Tài liệu hành chính bị <code>blocked</code> / <code>needs_review</code>
Schema	<code>TaiLieuKyThuat</code> , <code>BangKeVatTu</code> , <code>TechnicalAttributes</code>	Không có chỗ cho dữ liệu phi cơ khí
RBAC	<code>phong_ban_quyen = thu_muc</code> (1 chiều)	Không kiểm soát mức mật (lương, hợp đồng)

2. Kiến trúc đề xuất (tổng thể)

Upload → Tạo job (kèm domain gợi ý)
↓
Classifier 2 tầng:
 Tầng 1: routing domain (co_khi / ke_toan / nhan_su / ky_thuat / chung)
 Tầng 2: phân loại chi tiết trong domain
↓
Domain Registry → chọn:
 - Extractor phù hợp (mechanical | tabular | generic_text)
 - Schema lưu metadata
 - Hàm tính quality riêng
↓
Embed → Qdrant (payload kèm domain + security_level + department + site)
↓
Review/Publish → RBAC 2 chiều khi truy vấn

3. Thay đổi schema (SQL) — chạy idempotent



Giữ nguyên phong cách `IF NOT EXISTS` như file init mới để không phá dữ liệu cũ.

```
-- 3.1 Thêm cột phân loại vào TaiLieu
IF COL_LENGTH('dbo.TaiLieu','Domain') IS NULL
    ALTER TABLE dbo.TaiLieu ADD Domain NVARCHAR(50) NULL;
-- co_khi/ke_toan/nhan_su/ky_thuat/chung
IF COL_LENGTH('dbo.TaiLieu','SecurityLevel') IS NULL
    ALTER TABLE dbo.TaiLieu ADD SecurityLevel NVARCHAR(20)
NOT NULL DEFAULT 'internal'; -- public/internal/confidential
IF COL_LENGTH('dbo.TaiLieu','Site') IS NULL
    ALTER TABLE dbo.TaiLieu ADD Site NVARCHAR(100) NULL;
-- khu/xuong/site
```

GO

```
-- 3.2 Bảng metadata tổng quát (cho domain phi cơ khí)
IF NOT EXISTS (SELECT 1 FROM sys.objects WHERE object_id =
OBJECT_ID(N'dbo.DocumentAttributes') AND type='U')
BEGIN
    CREATE TABLE DocumentAttributes (
        AttrID          INT IDENTITY(1,1) PRIMARY KEY,
        DocID           INT NOT NULL,
        Domain          NVARCHAR(50) NOT NULL,
        AttributeKey    NVARCHAR(150) NOT NULL, -- vd: 'so_
hop_dong', 'ky_luong', 'phong_ban'
        AttributeValue  NVARCHAR(MAX) NULL,
        Confidence      FLOAT NULL,
        ExtractedBy     NVARCHAR(50) NULL, -- 'rege
x'|'llm'|'manual'
        CreatedAt       DATETIME DEFAULT GETDATE(),
        CONSTRAINT FK_DocAttr_TaiLieu FOREIGN KEY (DocID) R
EFERENCES TaiLieu(DocID) ON DELETE CASCADE
    );
    CREATE INDEX IX_DocAttr_Doc_Domain ON DocumentAttribute
s(DocID, Domain);
END
GO
```

```
-- 3.3 RBAC mức mật: quyền user theo (department x security
_level)
IF NOT EXISTS (SELECT 1 FROM sys.objects WHERE object_id =
OBJECT_ID(N'dbo.UserSecurityClearance') AND type='U')
BEGIN
    CREATE TABLE UserSecurityClearance (
        UserID          INT NOT NULL,
        MaxLevel        NVARCHAR(20) NOT NULL, -- 'publi
c'|'internal'|'confidential'
        PRIMARY KEY (UserID)
    );
END
GO
```

Nhớ cập nhật `delete_document_completely()` để xoá thêm `DocumentAttributes` (đã có `ON DELETE CASCADE` thì tự xoá, nhưng nên kiểm tra lại thứ tự).

4. Domain Registry (trung tâm cấu hình)

Tạo file mới `src/mech_chatbot/ingestion/domain_registry.py`:

```
from dataclasses import dataclass, field
from typing import Callable, List

@dataclass
class DomainConfig:
    key: str # 'co_khi'
    label: str # 'Cơ khí'
    departments: List[str] # các thư mục/phòng thuộc domain
    extractor: str # tên hàm extractor: 'mechanical'|'tabular'|'generic'
    quality_fn: str # tên hàm tính quality
    default_security: str = 'internal'

DOMAINS = {
    'co_khi': DomainConfig('co_khi', 'Cơ khí',
        ['To_Han', 'To_Dap', 'To_Son', 'To_Nham', 'To_Phoi', 'To_Tien_Phay',
         'To_Dong_Goi', 'To_Ban_Le', 'Bang_Ke', 'Gia_Cong_Ngoai'],
        extractor='mechanical', quality_fn='quality_mechanical'),
    'ky_thuat': DomainConfig('ky_thuat', 'Kỹ thuật', ['Ky_Thuat'],
        extractor='mechanical', quality_fn='quality_mechanical'),
    'ke_toan': DomainConfig('ke_toan', 'Kê toán', ['Ke_Toan'],
        extractor='tabular', quality_fn='quality_generic',
        default_security='confidential'),
    'nhan_su': DomainConfig('nhan_su', 'Nhân sự', ['Nhan_Su'],
```

```

        extractor='generic', quality_fn='quality_generic',
        default_security='confidential'),
    'chung': DomainConfig('chung', 'Chung', ['CHUNG', 'Tu_Ho
c'],
        extractor='generic', quality_fn='quality_generic',
        default_security='public'),
}

def resolve_domain_by_department(thu_muc: str) -> str:
    for d in DOMAINS.values():
        if thu_muc in d.departments:
            return d.key
    return 'chung'

```

5. Classifier 2 tầng

Sửa `classify_document()` để xác định domain TRƯỚC, rồi mới phân loại chi tiết:

```

def classify_document(file_path, original_filename=None, thu_muc=None):
    # Tầng 1: gọi ý domain từ thư mục/phòng ban upload
    domain = resolve_domain_by_department(thu_muc) if thu_muc else 'chung'

    text_content = extract_first_pages(file_path, 2)

    # Tầng 2: phân loại chi tiết – prompt tùy theo domain
    if domain in ('co_khi', 'ky_thuat'):
        parsed = _classify_mechanical(file_path, original_filename, text_content)
    else:
        parsed = _classify_generic(domain, original_filename, text_content)

    parsed['domain'] = domain
    return parsed

```



Quy tắc vàng: KHÔNG mặc định `technical_drawing` nữa. Nếu LLM lỗi và domain không phải cơ khí → fallback về `document_type='generic'` thay vì bản vẽ.

6. Router extractor theo domain

Trong `pdf_processor.py`, thay vì luôn gọi extractor cơ khí:

```
from mech_chatbot.ingestion.domain_registry import DOMAINS

def extract_attributes_by_domain(domain, text, info):
    cfg = DOMAINS.get(domain, DOMAINS['chung'])
    if cfg.extractor == 'mechanical':
        return extract_mechanical_attributes(text) # giữ
        nguyên hàm cũ
    elif cfg.extractor == 'tabular':
        return extract_tabular_attributes(text, info) # mớ
        i: số hoá đơn, kỳ, tổng tiền...
    else:
        return extract_generic_attributes(text, info) # mớ
        i: tiêu đề, ngày, người ký...
```

Ví dụ extractor generic (đơn giản, mở rộng dần):

```
import re

def extract_generic_attributes(text, info=None):
    out = []
    # Ngày tháng
    for m in re.finditer(r'\b\d{1,2}[/-]\d{1,2}[/-]\d{2,4}\b', text):
        out.append({'type': 'date', 'value': m.group(0), 'confidence': 0.8, 'extracted_by': 'regex'})
    # Số quyết định/hợp đồng dạng 123/2026/QĐ-...
    for m in re.finditer(r'\b\d+[/-]\d{4}[/-][A-Z\-\-]+\b', text):
        out.append({'type': 'doc_number', 'value': m.group(0), 'confidence': 0.8, 'extracted_by': 'regex'})
```

```
(0), 'confidence':0.75, 'extracted_by': 'regex'})
    return out
```

7. Quality scoring theo domain

Tách `calculate_quality_status()` thành nhiều hàm; không phạt "thiếu thuộc tính kỹ thuật" cho domain phi cơ khí:

```
def quality_mechanical(report):    # logic cũ giữ nguyên (ph
    at khi attrs == 0)
    ...

def quality_generic(report):
    total_pages = report.get('total_pages', 0)
    chunks = report.get('total_chunks', 0)
    if total_pages <= 0 or chunks <= 0:
        return 0, 'blocked'
    score = 100
    # Chỉ phạt khi KHÔNG trích được text nào
    if (len(report.get('pages_text_extracted', [])) == 0
        and len(report.get('pages_local_ocr_success', []))
== 0
        and len(report.get('pages_gemini_success', [])) ==
0):
        score -= 50
    if report.get('failed_pages'):
        return 0, 'blocked'
    return (score, 'ready_for_review') if score >= 90 else
(score, 'needs_review')

QUALITY_FUNCS = {'quality_mechanical': quality_mechanical,
'quality_generic': quality_generic}

def calculate_quality_status(report, domain='co_khi'):
    from mech_chatbot.ingestion.domain_registry import DOMA
    INS
    fn_name = DOMAINS.get(domain, DOMAINS['chung']).quality
```

```
_fn
    return QUALITY_FUNCS[fn_name](report)
```

8. RBAC 2 chiều khi truy vấn (quan trọng nhất về bảo mật)

Trong `rag/service.py`, mở rộng `create_rbac_filter()` để lọc đồng thời theo phòng ban VÀ mức mật:

```
from qdrant_client import models

LEVEL_ORDER = {'public': 0, 'internal': 1, 'confidential': 2}

def create_rbac_filter(user):
    allowed_depts = user.get('allowed_departments') or []
    max_level = user.get('max_security_level', 'internal')
    allowed_levels = [lvl for lvl, rank in LEVEL_ORDER.items()
                      if rank <= LEVEL_ORDER[max_level]]
    return models.Filter(must=[
        models.FieldCondition(key='metadata.phong_ban_quye
n',
                             match=models.MatchAny(any=allowed_depts)),
        models.FieldCondition(key='metadata.security_level',
                             match=models.MatchAny(any=allowed_levels)),
    ])
```



Bắt buộc kiểm thử: tài khoản tổ Hàn (`max_level='internal'`, không thuộc phòng Nhân sự) phải trả về 0 kết quả với tài liệu HR `confidential`. Viết test tự động cho ca này.

9. Cập nhật payload khi embed vào Qdrant

Khi nạp vector, bổ sung vào `metadata`:

```

metadata = {
    'file_goc': ten_file,
    'phong_ban_quyen': thu_muc,
    'domain': domain,                # MỚI
    'security_level': security_level, # MỚI
    'site': site,                    # MỚI
    # ... các field cũ
}

```

10. Kế hoạch migration từng bước (an toàn)

1. **Nhánh riêng:** `git checkout -b feature/multi-domain`.
2. **Chạy SQL mục 3** trên DB dev (idempotent, không phá dữ liệu).
3. **Backfill dữ liệu cũ:** đặt `Domain` cho tài liệu hiện có dựa trên `ThuMuc`:

```

UPDATE TaiLieu SET Domain = 'co_khi'
WHERE Domain IS NULL AND ThuMuc IN ('To_Han', 'To_Dap', 'To_Son', 'To_Nham',
    'To_Phoi', 'To_Tien_Phay', 'To_Dong_Goi', 'To_Ban_Le', 'Bang_Ke', 'Gia_Cong_Ngoai');
UPDATE TaiLieu SET Domain = 'chung' WHERE Domain IS NULL;

```

4. **Thêm** `domain_registry.py` và import vào classifier/processor.
5. **Sửa classifier (mục 5), router extractor (mục 6), quality (mục 7).**
6. **Cập nhật embed payload (mục 9)** và RBAC (mục 8).
7. **Re-embed lại tài liệu cũ** để thêm `domain/security_level` vào payload Qdrant (chạy script nền theo lô).
8. **Test** (mục 11) → review → merge.

11. Test plan tối thiểu

☐ Ingest 1 bản vẽ cơ khí → domain=co_khi, có thuộc tính kỹ thuật, quality ready.

- ☐ Ingest 1 file Excel kế toán → domain=ke_toan, KHÔNG bị phạt thiếu thuộc tính kỹ thuật.
- ☐ Ingest 1 quyết định nhân sự (PDF text) → domain=nhan_su, security=confidential.
- ☐ User tổ Hành query "bảng lương" → 0 kết quả (RBAC chặn).
- ☐ User HR query bảng lương → có kết quả.
- ☐ Xóa 1 tài liệu mọi domain → không còn dòng ở `TaiLieu`, `DocumentAttributes`, và vector Qdrant.
- ☐ Re-embed: tài liệu cũ sau khi re-embed có `domain` trong payload.

12. Hướng dẫn từng bước cho bạn (checklist thực thi)

- ☐ Bước 1 — Backup DB hiện tại trước khi đùng schema.
- ☐ Bước 2 — Tạo nhánh git riêng.
- ☐ Bước 3 — Chạy SQL mục 3 trên dev, kiểm tra bảng/cột mới đã có.
- ☐ Bước 4 — Backfill `Domain` cho dữ liệu cũ (mục 10.3).
- ☐ Bước 5 — Thêm `domain_registry.py`.
- ☐ Bước 6 — Sửa classifier 2 tầng (mục 5).
- ☐ Bước 7 — Thêm extractor generic/tabular + router (mục 6).
- ☐ Bước 8 — Tách quality theo domain (mục 7).
- ☐ Bước 9 — Cập nhật RBAC 2 chiều (mục 8) + clearance trong `auth`.
- ☐ Bước 10 — Cập nhật embed payload (mục 9) + re-embed dữ liệu cũ.
- ☐ Bước 11 — Chạy đủ test plan (mục 11).
- ☐ Bước 12 — Review code, merge, deploy lên staging trước khi production.